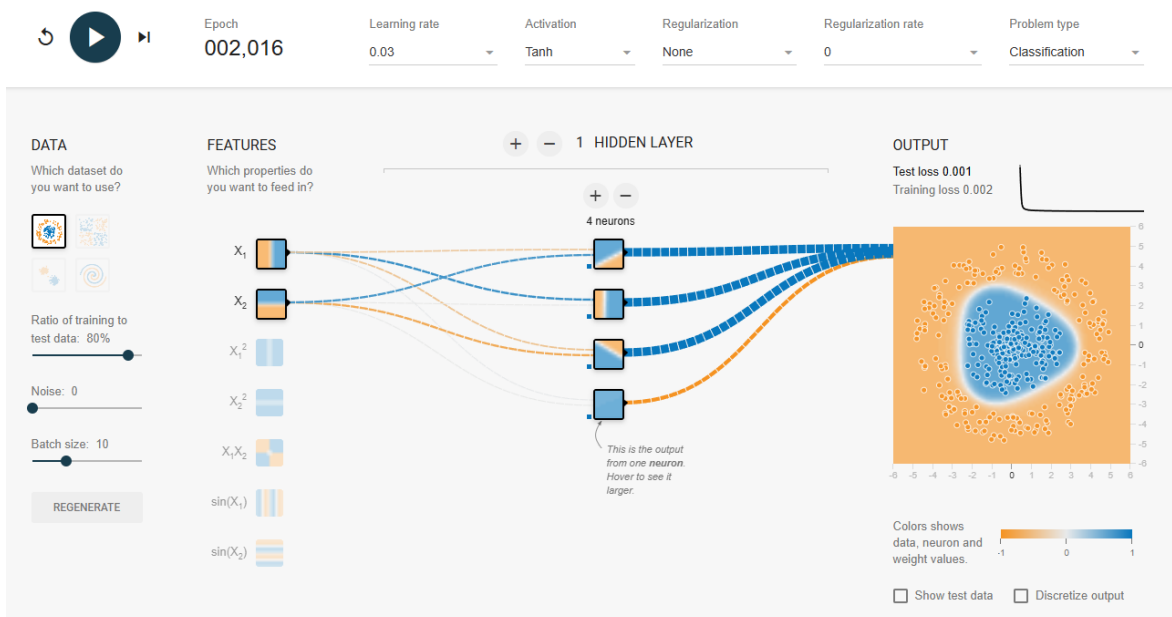


## Análisis

La red neuronal ha sido entrenada para clasificar datos en dos categorías (problema de clasificación). Parece estar funcionando bastante bien, ya que tanto la pérdida de entrenamiento (0.002) como la pérdida de prueba (0.001) son muy bajas. Esto sugiere que la red ha aprendido a generalizar patrones de los datos y no solo está memorizando los ejemplos de entrenamiento.



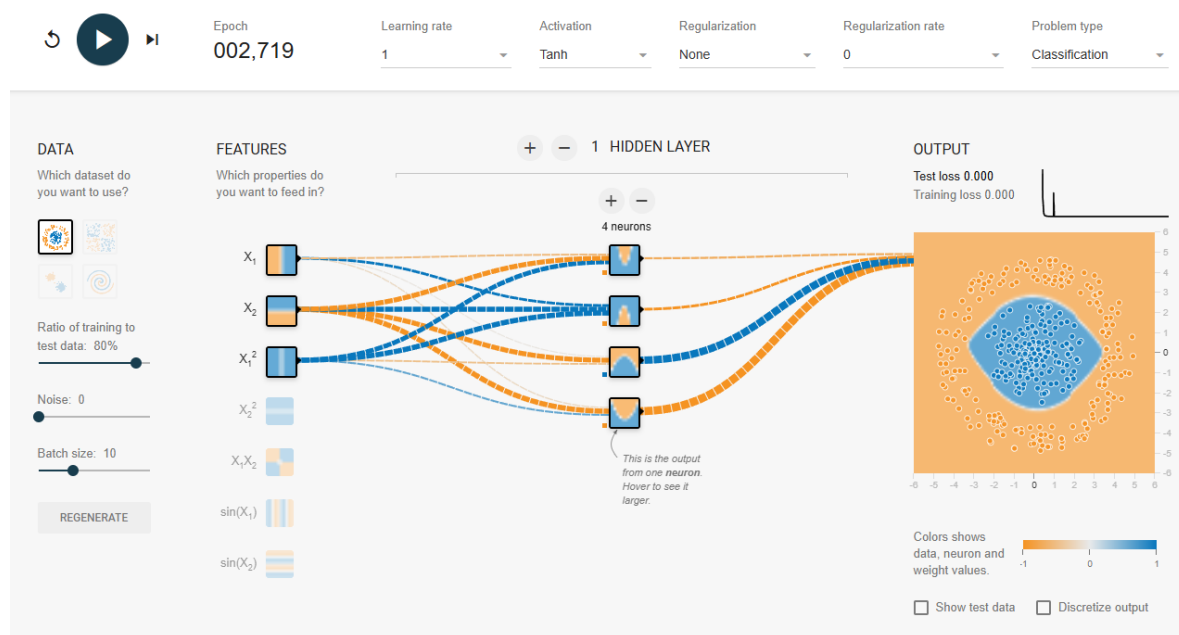
## Análisis

Si la cuarta neurona no recibe datos y su caja está azul, pero las líneas de conexión son grises, esto podría indicar lo siguiente:

- **No recibe datos:** Significa que ninguna de las características de entrada ( $X_1$ ,  $X_2$ ,  $\sin(X)$ ,  $\sin(X^2)$ ) está conectada a esta neurona. Las líneas grises que deberían representar estas conexiones están ausentes o son muy débiles, lo que indica que los pesos de conexión son cero o muy cercanos a cero.
- **Caja azul:** El color azul de la caja generalmente indica que la neurona está activa y contribuyendo a la salida de la red. Sin embargo, en este caso, dado que no recibe datos, su activación probablemente se deba a un sesgo (bias) constante que tiene la neurona. El sesgo es un parámetro adicional que permite a la neurona activarse incluso sin entrada.
- **Líneas grises:** Las líneas grises que conectan la neurona con la capa de salida indican que los pesos de conexión son cero o muy cercanos a cero. Esto significa que la activación de esta neurona no influye en la salida de la red.

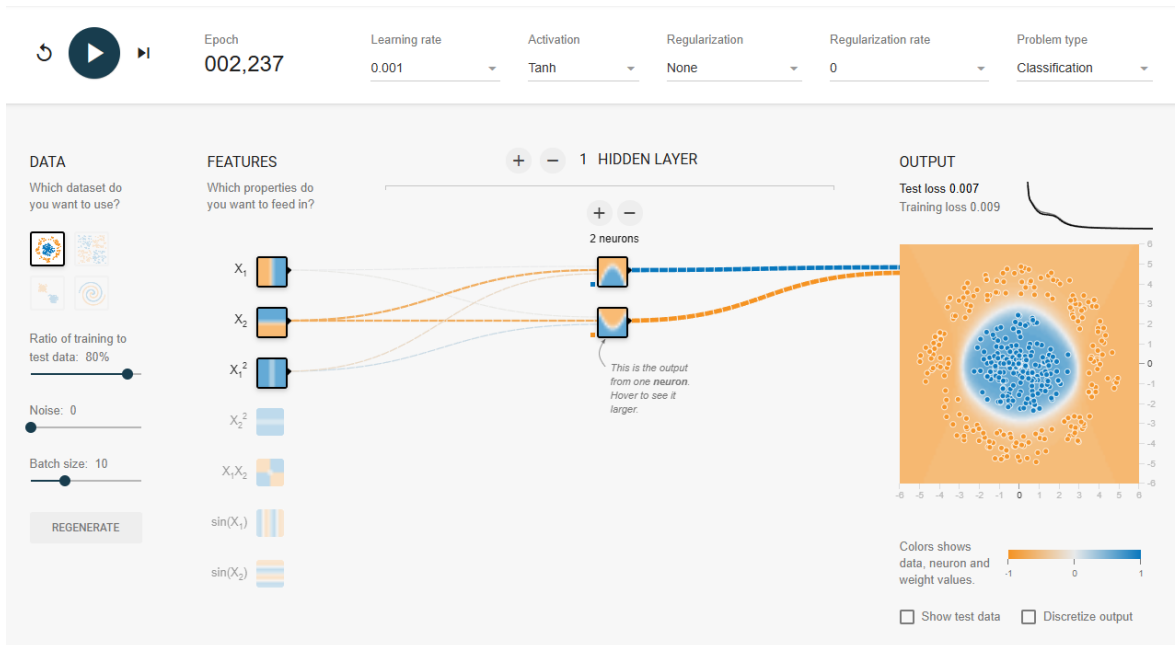
## Interpretación:

Esta situación sugiere que la cuarta neurona es esencialmente irrelevante para la tarea de clasificación que está realizando la red neuronal.



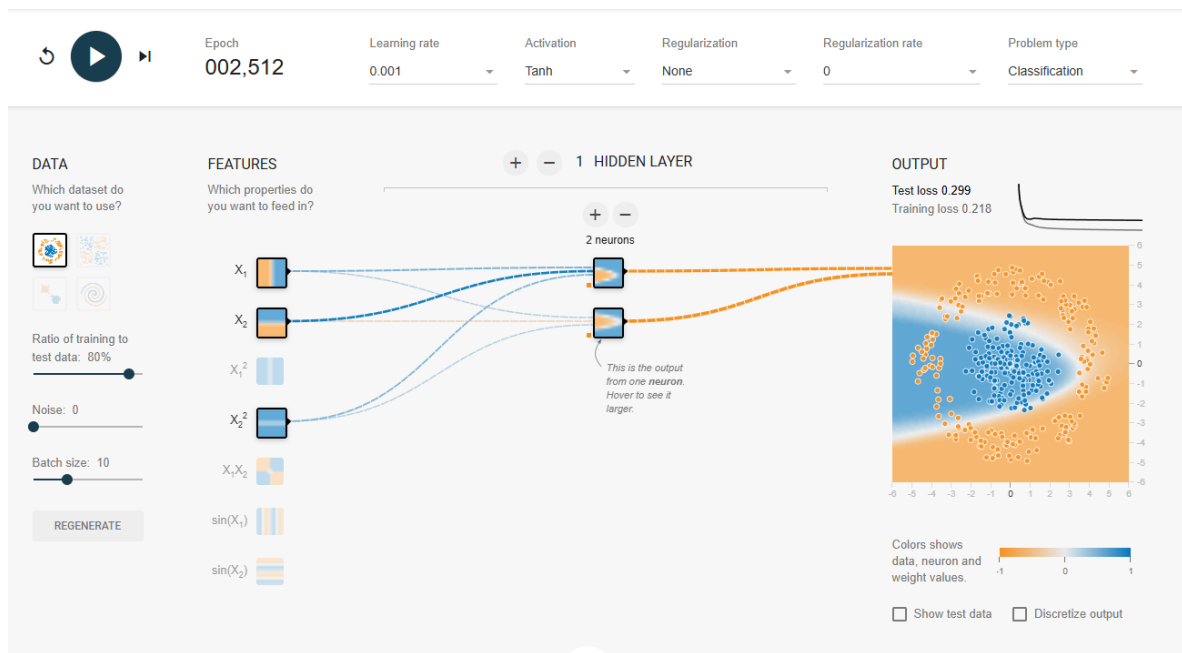
## Análisis

- **Sobreajuste (Overfitting):** La principal preocupación con una tasa de aprendizaje tan alta y una pérdida de entrenamiento tan baja es que el modelo no generalizará bien a datos nuevos.
- **Importancia de las Características:** Aunque  $X_1X_2$  parece dominar, las otras características también contribuyen, lo cual es positivo para la diversidad del modelo.



## Análisis

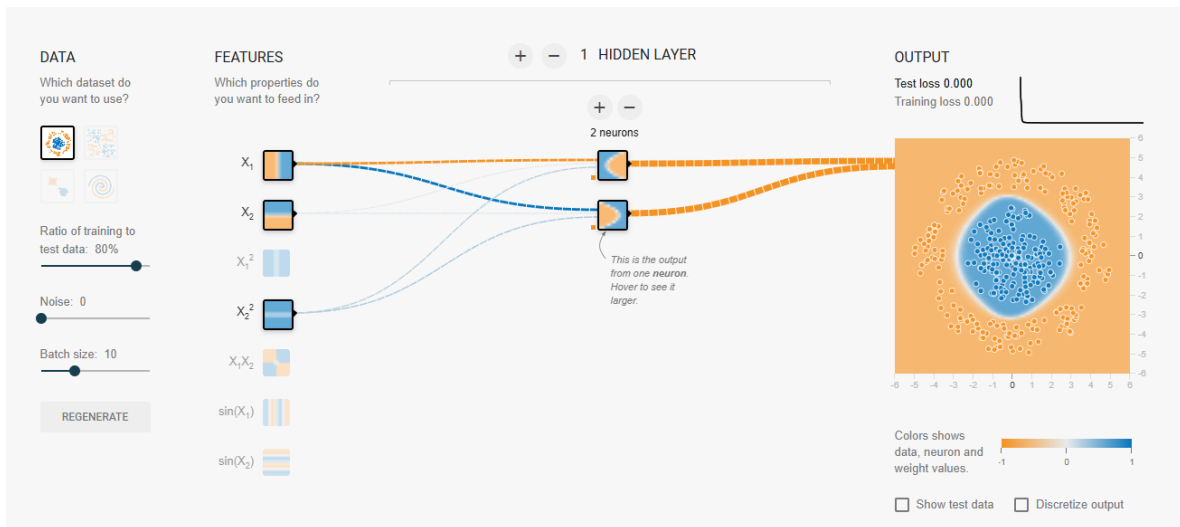
Reducir la tasa de aprendizaje ha cambiado la forma en que la red neuronal aprende y se comporta. Aunque las pérdidas han aumentado ligeramente, la red podría ser más robusta y generalizar mejor a nuevos datos. Sin embargo, es posible que se necesite más tiempo de entrenamiento para alcanzar su máximo potencial.



Este cambio en el gráfico de salida se debe principalmente a la modificación en las características de entrada.

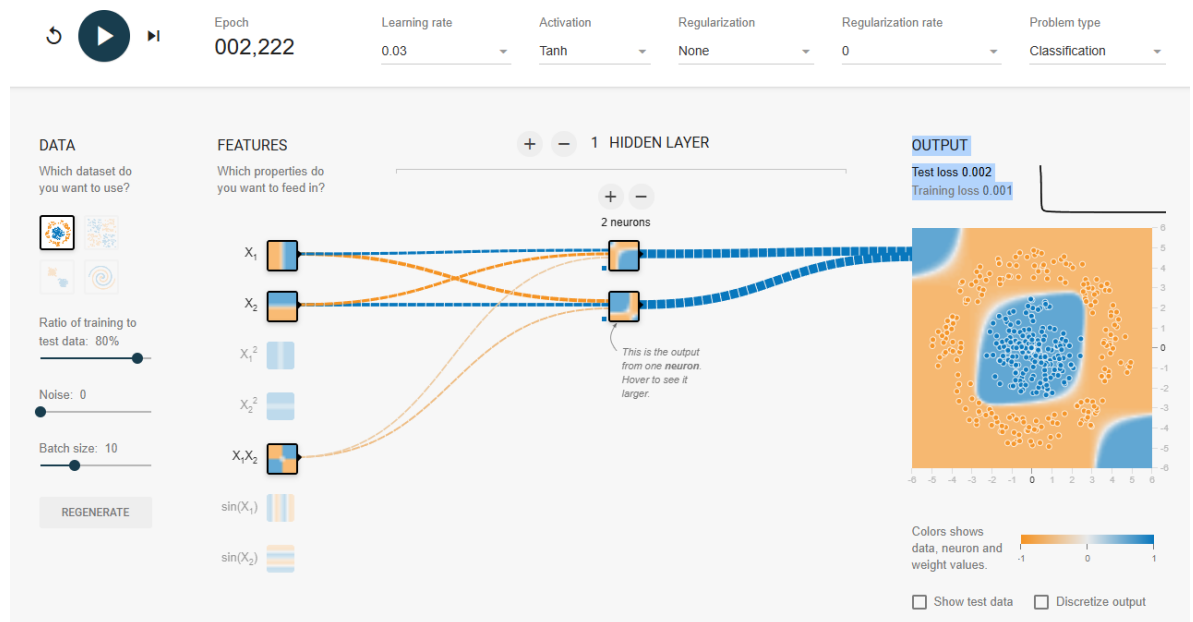
La inclusión de  $X_2^2$  en lugar de  $X_1^2$  parece haber introducido una no linealidad más pronunciada en el modelo. Esto significa que la relación entre las características de entrada y la salida predicha por la red neuronal es más compleja.

El cambio en la frontera de decisión también se refleja en las pérdidas de entrenamiento y prueba, que han aumentado considerablemente en comparación con la imagen anterior. Esto sugiere que la red neuronal está teniendo más dificultades para aprender a clasificar los datos con esta nueva configuración de características.



El aumento de la tasa de aprendizaje ha tenido un impacto significativo en el rendimiento de la red neuronal:

- **Aprendizaje más Rápido:** Una tasa de aprendizaje más alta permite que la red realice ajustes más grandes en sus pesos durante cada iteración de entrenamiento. Esto acelera el proceso de aprendizaje y permite que la red converja más rápidamente a una solución óptima.
- **Mejor Rendimiento:** La reducción drástica de las pérdidas y la mejora en la frontera de decisión indican que la red ha aprendido a clasificar los datos de manera mucho más precisa con la tasa de aprendizaje más alta.



En esta imagen comparada con la anterior se ve que modificar el learning rate, produce una variabilidad en los resultados vs cambiar las características.